


# 基于趋势促进价格跟踪集成学习算法的在线投资组合策略



Knowledge-Based Systems

Volume 239, 5 March 2022, 107957



## 摘要

如何高效、合理地进行投资组合已经成为一个热点问题。针对目前预测股价投资的不稳定性和投资比例难以确定的问题,提出了趋势峰价跟踪法。首先,由于股价异常的影响,TPPT策略设置了可调整的历史窗口宽度。利用斜率值判断预测方向跟踪价格变化,采用指数移动平均和峰值等权斜率值三态价格预测方法。其次,对累积财富目标进行细化,并加入基于梯度投影算法(BP)的快速误差反向传播算法。该算法求解投资比例,并将资产的增值能力反馈到投资比例上,以使积累的财富最大化。最后,通过五个典型数据对八种策略的实证分析和统计检验,表明TPPT策略在平衡风险和收益方面具有很大的优势,是一种稳健有效的在线投资组合策略。

关键词: 网上证券投资; 价格异常; 三态价格; 集成学习算法; 投资比例

## 1 引言

在线投资组合选择是计算金融中的一个基本问题,已经在多个研究领域得到了广泛的研究,包括金融、统计学、人工智能、机器学习和数据挖掘。在不确定的市场环境中,如何不断地选择最优投资组合,使金融证券市场的累积收益最大化或损失最小化,是证券投资的关键问题。

根据凯利的资本增长理论,将投资组合策略分为五个部分:基准策略、跟随赢家策略、跟随输家策略、模式匹配方法和元学习算法。此类选择方法主要基于股票的单一效应或股票样本的相似性原则,难以贴合股价畸变的实际要求,且较长的拦截时间窗口对预测也存在显著的不稳定性。此外,随着所需信息量的增加和对数据质量要求的提高,算法的复杂度也会在实际投资中增加。

本次课程的论文复现工作拟采用论文所述的一种基于趋势驱动集成学习算法的在线投资组合策略,即趋势峰值价格跟踪(TPPT)。集成学习的思想不仅考虑了股票价格异常的复杂性,而且结合了各种算法的优点,提高了模型的泛化能力。最后通过五个典型数据对八种策略的实证分析和统计检验,表明TPPT策略在平衡风险和收益方面具有很大的优势,是一种稳健有效的在线投资组合策略。

## 2 相关工作

在线投资组合选择的本质是一个优化问题。在复杂的金融背景下,样本的选择和算法的设置都会影响最终的风险收益效果。Tavana等人[10]在最优化的基础上提出了一种随机回归数学规划模型。在该研究中,收入由随机变量表示,未来的预期总收入在给定的分位数概率水平上最大化。Gao和Yang[11]增加了L1范数来约束投资组合权重。他们使用近端梯度投影方法来跟踪价格趋势。在机会约束下,Han和Li[12]提出了一种非对称近似方法,即基于

鲁棒优化技术的机会约束投资组合选择模型。此外, 为了实现全局优化, Nyikosa 等人.[13] 将动态环境中的函数建模作为黑盒。他们利用高斯过程推理机制, 在黑箱模型(目标函数)中加入了大量的先验信息。Zhang 等[14]提出可以用相对熵作为距离函数, 用线性函数求解投资区间。由于时间序列的非平稳性和单一模型的低效性, Yu 和 Huang [15]提出了在线自回归移动回归策略(OLAR)。提出了 OLAR 策略, 通过在线学习框架中 ARIMA 模型简化设计封闭格式, 在线被动供给算法调整投资策略, 对模型进行优化。此外, 在基本框架原型下, 学者们还加入了许多更贴近真实的生活的细节, 包括相对价格的求解、算法的演化、策略的应用领域等, 以增强策略的泛化能力和实用性。

## 2.1 相对价格

在线投资组合选择中的相对价格对于后期的趋势预测和投资非常重要, 是选择合适的样本预测下一时期相对价格的关键步骤。防御性策略包括 EMA、RMR 等, 其中简单移动平均线(SMA)和指数移动平均线(EMA)是最具代表性的策略。此外, Li 和 Hoi [2]提出了一种选择在线移动平均法来求解下一时期相对价格的方法。Huang 等人[5]提出了一种 RMR 策略, 该策略选择先前窗口数据的 L1 范数作为相对价格。而 PPT 策略等进取型策略则直接利用最大值来预测相对价格。在模式匹配策略中, 样本选择主要用于选择相似的历史相对价格指数集。包括基于非参数核的样本选择方法、最近邻选择方法、基于相关性的样本选择方法等。但这类选择方法主要基于股票的单一效应或股票样本的相似性原则, 难以贴合股价畸变的实际要求。拦截时间窗长, 对预测也有很大的不稳定性。

## 2.2 进化算法

最终累积的财富主要取决于相对价格预测和相应的增长因子。

围绕这两个关键因素, 学者们进行了大量的研究, 如随机化信息和基数约束等。外部信息的加入考虑到了实际股票交易的复杂性, 对股票投资交易的深入研究具有重要意义。随机信息、基数约束、交易成本和边信息的加入是对原有框架的变形, 是对在线投资组合策略的丰富和扩展。

在这些基本条件的调整下, 各种算法也发生了很大的进化, 使得在线投资组合策略得到了进一步的研究。例如, Skrinjaric [16]提出了一种新的基于趋势表示的对数密度正则化投资组合优化系统。在加权岭回归模型中, 将增长因子和时间变量加入回归变量, 以捕捉价格趋势模型。Bean 和 Singer [17]将随机信息和约束项添加到梯度更新计算中。他们应用约束随机近似算法推导出扩展的指数梯度投资组合。基于投资者对下行损失和上行收益的非对称态度, 艾凡[18]等人提出了一种非对称分布不确定集合的鲁棒多期投资组合选择。考虑到引入原始模型限制资产数量的基数约束问题, Akbay 等人[19]提出了一种基于基数约束的解决投资组合优化问题的两阶段方法, 其中增加了一种基于二次规划的并行变邻域搜索算法。

在交易费用约束下, 增加资产数量和资产比例, 朱等[20]提出了一种基于基数约束和交易费用的在线投资组合选择方法。考虑到交易成本, Wu 等人[21]增加了由高频交易引起的高频交易成本。他们提出了一种基于机器学习和在线学习理论的半指数梯度策略(SEG)。该方法通过对投资周期进行分段, 利用因子图算法求解下一个投资组合迭代更新的封闭解, 得到新一个投资组合周期向量。

Qu 等人[22]设计了在线牛顿步交易策略(ONST)。莫拉等人[23]发现, 增加动态条件相关模型和随机波动率模型可以为投资组合提供更稳定的回报。由于计算和成本有关的参数数量或参数频繁更新。Puja 等人[24]指出, 基于原始对偶算法的在线惰性更新算法(OLU)成功地处理了随机优化更新模型。考虑到频繁变化的投资组合的巨大成本, Das 等人.[25]提出了一种具有群体稀疏性框架的通用延迟在线学习系统。

## 2.3 集成学习算法的改进

近年来,集成学习算法在提高其泛化能力和应用范围方面得到了更广泛的推广。由于在线投资组合选择已经引起了实践者和研究者的极大关注,郭[32]提出了一种自适应在线移动平均方法(AOLMA),通过将自适应衰减因子引入移动平均方法来预测风险资产的未来收益,该方法通过加入净利润最大化模型(NPM)来提高收益预测的准确性。由于传统的均值-方差投资组合策略不具有鲁棒性,周[33]集成了股票选择和投资权重模型。他提出了多数据源的数据包络分析(DEA),并利用支持向量机(SVM)结合股票的多源数据对股票价格走势进行预测,将股票价格走势与提出的选股方案相结合,构建了投资组合优化模型。针对投资者对收益和风险的不对称情绪对投资组合策略更新的重要性,提出了一种动态情绪调整模型(DSAM)来解决多期稀疏投资组合选择问题[34]。将具有重参数化技术的随机神经网络算法(SNNrP)引入到动态情绪调整模型中,采用最小化投资组合风险的优化模型,解决多时段稀疏投资组合选择问题。

## 2.4 应用范围

在线证券组合选择的优化思想可以应用到各个领域。相关价格组合的最优算法首次解决了价格相互相关的市场中的在线投资组合选择问题[35]。在微博上,人们发布了他们对股票上涨和下跌的感受,Koyano和Ikeda[36]在跟随失败者原则中提出了一种新的策略,通过监督学习来估计缺失的情绪并将其用于预测股票价格。上海证券交易所的经验表明,投资组合选择模型的性能在很大程度上取决于参数估计和初始资产选择。Chen等人[37]的混合算法解决了具有高阶矩的投资组合选择问题,并将其推广到典型的均值-方差模型。Yang等人[38]在金融理论投资策略的研究中加入了灰色关联分析,其研究重点是收益分布。由此产生的投资组合价值大于基本技术分析的战略价值。在相对价格解、算法选择、策略适用范围等方面,TPPT策略都有不同程度的扩展。在求解相对价格方面,TPPT策略采用集成学习算法的思想,设置了可调的历史窗口期长度。TPPT策略考虑到股票异常中的趋势效应和反转效应,利用斜率来识别方向,激活三种状态下的下一期价格,求解相对价格。在算法选择上,采用基于梯度投资响应的BP算法结合方向判别下的相对价格,采用集成学习算法求解投资比例。TPPT策略是一种有效的在线投资组合选择策略,更符合实际的投资过程,并将探索投资的核心思想。

# 3 本文方法

## 3.1 本文方法概述

- [1] 提出了一种新的动态股价预测方法。TPPT策略是指通过设定可调的历史窗口宽度,利用趋势线判断股价走势的思想,利用两点间斜率的等权线性组合来判断股价走势。
- [2] 提出了一种三态股价预测方法,在判断股票走势后,通过等权斜率的线性组合来激活下一次股价预测。当斜率值之和小于零时,考虑趋势效应,采用窗口期峰值。当斜率值之和大于零时,考虑反演效果,采用指数滑动平均算法。当斜率值之和为零时,将保持当前库存值。
- [3] 提出了一种新的策略TPPT策略,利用集成学习算法策略五原则的思想,TPPT策略遵循赢家策略和输者策略,并加入基于梯度投影的快速BP算法,得到投资组合的投资比例,以最大化积累的财富。

## 3.2 拟复现的具体内容

复现TPPT算法（采用等权斜率的线性组合来判断价格变化的方向，以激活三态价格预测方法），并加入基于梯度投影算法（BP）的快速误差反向传播算法。

通过五个典型数据DJIA、NYSE(O)、NYSE(N)、SP500、TSE的对八种策略的累积财富Cumulative wealth、年化收益Annualized return、夏普比率Sharp Ratio、卡尔马比率Calmar Ratio、平均超额收益Average Excess Return、胜率Winning Rate进行比较，并将结果可视化。

---

Algorithm 1 TPPT strategy

---

**Input** Current closing price  $\{p_{t-k}\}_{k=0}^{\omega-1}$ .

**Output** Investment proportion in next period  $\hat{\mathbf{b}}_{t+1}$

- (1) Initialization: window length  $W=5$ , constraint parameter  $\epsilon = 100$ .
- (2) for  $t = 1$  to  $n$
- (3) for  $i = 1$  to  $m$
- (4) Calculate the slope value  $k_t^i$ .
- (5) if  $k_t^i > 0$
- (6) the next stock price  $\hat{p}_{t+1}^i$  is ( $\alpha$  is 0.5):
- (7)  $\alpha p_{t+1}^i + \alpha(1-\alpha)p_{t-3}^i + \alpha(1-\alpha)^2 p_{t-2}^i + \alpha(1-\alpha)^3 p_{t-1}^i + \alpha(1-\alpha)^4 p_t^i$ .
- (8) elseif  $k_t^i = 0$ .
- (9)  $\hat{p}_{t+1}^i = p_t^i$ .
- (10) else
- (11)  $\max_{0 \leq k \leq \omega-1} p_{t-k}^i$ .
- (12) end if
- (13) end if
- (14) Calculate the relative price vector:  $\hat{\mathbf{x}}_{t+1} = \frac{\hat{\mathbf{p}}_{t+1}}{\mathbf{p}_t}$ .
- (15) Calculate investment proportion vector:  $\tilde{\mathbf{b}}_{t+1} = \hat{\mathbf{b}}_t + \mathbf{c}_{t+1}$ .
- (16) Projection the investment vector 0~1:

$\hat{\mathbf{b}}_{t+1} = \operatorname{argmax}_{\mathbf{b} \in \Delta_d} \mathbf{b}^\top \hat{\mathbf{x}}_{t+1}$ .

---

图1 TPPT算法设计思路

## 4 复现细节

### 4.1 与已有开源代码对比

工程文件参考了 github 上的 <https://github.com/Marigold/universal-portfolios>。此工程文件搭建了一个框架去比较各类算法的效益。

本实验增加了编写的 tppt 算法的文件，并增加了一些对比算法的文件，去证明论文的实验结果。并在 TPPT 的算法基础上尝试去考虑更多的集成算法，测验是否有更好效益。

### 4.2 实验环境搭建

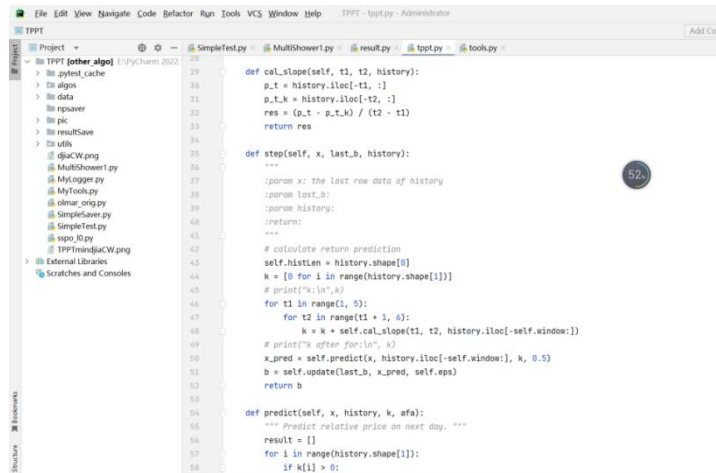


图2 实验环境搭建

### 4.3 使用说明

- [1] Data 文件存储了五个数据集的相对价格的 pkl 文件
- [2] Algos 存放了 tppt 以及其他对比算法的文件
- [3] Pic 存放了 CW 累积财富各个算法在不同数据集的结果对比折线图
- [4] resultSave 文件夹保存了每个数据集在不同算法上运行得到的实验对象，方便后续画图
- [5] Utils 是一些工程文件。

### 4.4 创新点

对 tppt 算法进行改进，使得累积财富效果更好。

$$\hat{p}_{t+1}^i = \begin{cases} \alpha p_{t+1}^i + \alpha(1-\alpha)p_{t-3}^i + \alpha(1-\alpha)^2 p_{t-2}^i + \alpha(1-\alpha)^3 p_{t-1}^i \\ + \alpha(1-\alpha)^4 p_t^i, \sum_{j=1}^{10} k_j^i > 0 \\ p_t^i, \sum_{j=1}^{10} k_j^i = 0 \\ \max_{0 \leq k \leq \omega-1} p_{t-k}^i, \sum_{j=1}^{10} k_j^i < 0 \end{cases}$$

图 3 论文原预测价格方式

基于这个集成预测价格的方式,我们可以去思考把 max 改成 min 或者 average 等方式,去运行并查看最后的 CW。

下图是跟随赢家策略累积财富趋势图,低风险策略累积财富趋势图,跟随输家策略累积财富趋势图。可以看出还是原文中跟随赢家趋势图累积财富的效果突出。




图 3  $p\_hat = \max(\text{history.iloc[:, i]})$  跟随赢家策略累积财富趋势图




图 4  $p\_hat = \text{sum}(\text{history.iloc[:, i]} / \text{len}(\text{history}))$ 低风险策略累积财富趋势图




图 5  $p\_hat = \text{min}(\text{history.iloc[:, i]})$ 跟随输家策略累积财富趋势图

或者去调整  $a$  值，会发现当  $a=0.3$  时发现比论文中默认的  $0.5$  结果要好。




图 6 当  $a=0.3$  时的累积财富趋势图




图 7 当  $a=0.5$  时的累积财富趋势图


## 5 实验结果分析

$$\hat{S}_n = \prod_{i=1}^n (\mathbf{b}_i^\top \mathbf{x}_i)$$

Cumulative Wealth (CW)该指数反映了该策略在整个交易周期内实现的总收益和总资本的变化率。它等于期末的总资本除以期初的总资本，这是衡量战略绩效的标准。

除 TSE 数据集外，TPPT 策略累计财富值排名第二，TPPT 策略在其他四个数据集均排名第一，显示出其优势。同时，交易数据量越多，TPPT 策略表现越明显。NYSE (O) 和 NYSE (N) 都是数据量较大的，其累计增长财富值较其他数据集更为明显，分别以 1.4544 亿 1018 和 3.0949 亿 109 位居第一。

复现折线图（DJIA 的数据累积财富趋势图）如下：



## 6 总结与展望

投资组合中的资产配置是人们关心的核心问题。在这项研究中，在线投资组合策略（TPPT）的价格趋势驱动集成学习算法的基础上提出的。将积累的财富反馈到投资比例，在灵活多变的窗口设置下载取历史日数据，跟踪股票的趋势效应和反转效应。利用三态斜率方向判别法计算下一期的相对股价，消除了含有不稳定因素的时间序列数据的维数和过长。然后利用基于梯度投影的 BP 算法得到具体的投资比例。投资者可以通过投资比例来配置相应的投资组合，以简化投资过程，实现投资财富的最大化。此后，8 种经典策略在 5 个经典数据集上的对比实验表明，TPPT 策略在累积财富、年化收益率、锐比、胜率等指标上的收益和风险能力都有明显优势，表现也不错。因此，TPPT 策略是一种有效的均衡收益和风险的在线投资组合策略。但是，由于本研究将实际情况理想化，因此设置了无交易费用的前提。另外，BP 算法中采用的基于梯度投影的策略没有考虑零数据集可能带来的影响（算法失效）。用于计算投资比例的算法可以借鉴稀疏在线学习等算法。在未来的研究中，可以加入更多的实际因素，如交易费用，并增加算法失败时的计算方法。因此，在线投资组合策略问题需要进一步研究。



## 参考文献

- [1] A. Moghaddam, M. Moghaddam, M. Esfandyari, Stock market index prediction using artificial neural network, *J. Econ. Financ. Adm. Sci.* 21 (2016) 89–93.
- [2] B. Li, S.C. Hoi, Online portfolio selection: A survey, *ACM Comput. Surv.* 46(3) (2014) 1–36.
- [3] H.L. Yao, M.C. Du, J.Z. Li, Stock market tracking prediction algorithm based on stream feature model, *Comput. Sci.* 40 (12) (2013) 45–51, (In Chinese).
- [4] Z.R. Lai, D. Dai, C. Ren, A peak price tracking-based learning system for portfolio selection, *IEEE Trans. Neural Netw.* 29 (7) (2018) 2823–2832.
- [5] D. Huang, J. Zhou, B. Li, Robust median reversion strategy for online portfolio selection, *IEEE Trans. Knowl. Data Eng.* 28 (9) (2016) 2480–2493.
- [6] L. Gao, W. Zhang, Weighted moving average passive aggressive algorithm for online portfolio selection, in: *Proc of the 5th International Conference on Intelligent Human-Machine Systems & Cybernetics*, IEEE Computer Society, Washington, DC, 2013, pp. 327–330.
- [7] X. Cai, Z. Ye, Gaussian weighting reversion strategy for accurate online portfolio selection, *IEEE Trans. Signal Process.* 21 (67) (2019) 5558–5570.
- [8] X. Lin, M. Zhang, Y.F. Zhang, et al., Boosting moving average reversion strategy for online portfolio selection: A meta-learning approach, in: *Proc of International Conference on Database Systems for Advanced Applications*, Springer, Cham, 2017.
- [9] H. Guan, Z. An, A local adaptive learning system for online portfolio selection, *Knowl. Based Syst.* 186 (104958) (2019) 1–10.
- [10] M. Tavana, R.K. Shiraz, D.D. Caprio, A chance-constrained portfolio selection model with random-rough variables, *Neural Comput. Appl.* 31 (2) (2019) 931–945.